

# MACHINE LEARNING PARA ECONOMISTAS

2022 – II

<b>Profesor:</b>	Francisco Rosales	<b>Horario:</b>	Lun: 7:30 – 09:20
<b>Jefe de Prácticas:</b>	Ronie Arauco	<b>Horario:</b>	Mie: 7:30 – 09:20
<b>Código del Curso:</b>	130465	<b>Créditos:</b>	3
<b>Departamento:</b>	Economía	<b>Sección:</b>	A

**Office Hours:** Lun: 9:20 – 10:00 en la UP.

**Resumen:** Machine Learning para Economistas es un curso electivo de 3 créditos del departamento académico de Economía. Su único pre-requisito es Econometría I. Tiene 4 horas de dictado a la semana (2 horas de teoría y 2 horas de práctica). Este curso presenta métodos de aprendizaje supervisado con énfasis en problemas de clasificación y regresión. El curso incluye sesiones de fundamentos matemáticos; y sesiones de desarrollo metodológico y aplicaciones en economía. Se usará el software Python para la presentación de ejemplos y casos de estudio. Se espera que los estudiantes conozcan los elementos básicos de programación (definición de variables, recurrencias, uso de funciones), en algún lenguaje, Eviews, por ejemplo. En las sesiones de práctica se realizarán ejercicios utilizando Python, y el aprendizaje se realizará resolviendo problemas de machine learning.

**Resultados del Aprendizaje:** Al finalizar la asignatura, el estudiante alcanzará los siguientes objetivos

- Utilizar adecuadamente conceptos matemáticos básicos en los métodos de machine learning, y poder explicarlos a un nivel teórico, y no sólo intuitivo.
- Saber aplicar el trade off explicabilidad vs predictibilidad. Es decir, desarrollar la capacidad de seleccionar los modelos más convenientes para los fines de la aplicación.
- Utilizar el software Python y sus librerías especializadas a un nivel básico. Se espera que los estudiantes puedan leer críticamente el código desarrollado por terceros y hacer modificaciones al mismo.

**Competencias:** El curso desarrolla las siguientes competencias en los estudiantes de economía:

- Generales (Graduado de la UP)
  - Responsabilidad: los estudiantes deben aprovechar las herramientas de aprendizaje que se les proporcionan, p. sesiones de ejercicios impartidas por el TA, apuntes de clase subidos a Blackboard, horarios de oficina, etc.
  - Panorama general: el estudiante debe vincular las herramientas matemáticas proporcionadas en la lección con los temas que ve en otros cursos de economía o finanzas.
- Específicas (Graduado de Economía y Finanzas)

- Herramientas cuantitativas: el curso proporciona herramientas básicas que deben facilitar la comprensión de la economía y las finanzas modernas.
- Capacidad investigadora: se fomenta mucho la curiosidad intelectual en la asignatura. Los estudiantes deben hacer ejercicio su capacidad para pensar creativa y matemáticamente.

### Unidades Académicas:

- Unidad de aprendizaje 1: Modelos lineales - conceptos Básicos  
Al finalizar la unidad de aprendizaje, el estudiante estará en capacidad de explicar el modelo lineal generalizado, discutir sus limitaciones y de implementarlo en el software Python.
  - Aprendizaje estadístico
  - Introducción a Python
  - Modelo lineal generalizado
- Unidad de aprendizaje 2: Modelos lineales - reducción Dimensional  
Al finalizar la unidad de aprendizaje, el estudiante estará en capacidad de hacer selección de variables en modelos lineales mediante métodos iterativos y utilizando variables latentes mediante PCR, PLS y modelos de penalización Lasso.
  - Selección de modelos lineales
  - PCR/PLS
  - Regesión Ridge/Lasso
- Unidad de aprendizaje 3: Modelos no-lineales  
Al finalizar esta unidad de aprendizaje, el estudiante estará en capacidad de implementar e interpretar los resultados de un modelo de clasificación y regresión no-lineal.
  - Modelo aditivo generalizado
  - Máquinas de vectores de soporte
  - Random Forest
  - Redes Neuronales

### Estrategia de Aprendizaje:

- El profesor presentará la teoría y algunos ejemplos ilustrativos durante la clase.
- El jefe de práctica resolverá ejercicios para preparar a los estudiantes para las prácticas calificadas.
- Los estudiantes deben leer el libro de texto principal y prepararse para las clases por su cuenta para aprovechar las clases al máximo.

**Evaluación:** 4 prácticas calificadas (40%) y un trabajo final (60%). La práctica calificada 1 es teórica y es individual. Las prácticas calificadas 2, 3 y 4, y el trabajo final son grupales, son para la casa y son para programar en python. Se elimina la nota más baja de las prácticas calificadas.

**Referencias Principales:** La referencia principal del curso es *Introduction to Statistical Learning*. Se hará referencia a los otros libros de texto para profundizar en algunos conceptos específicos.

- AICDA Agresti, A. (2019). *An introduction to Categorical Data Analysis*. John Wiley & Sons.
- CRT Breiman, L. et. al (1984). *Classification and Regression Trees*. Taylor & Francis.
- ESL Hastie, T., R. Tibshirani and J. Friedman (2009). *The Elements of Statistical Learning: Data Mining, Inference and Prediction*. Springer Series in Statistics.
- ISLAR James, G. et. al (2013). *An Introduction to Statistical Learning with Applications in R*. Springer Series in Statistics.
- SPR Ruppert, D., M. Wand and R. Carroll (2003). *Semiparametric Regression*. Cambridge Series in Statistical and Probabilistic Mathematics.
- LWK Schölkopf, B., A. Smola (2002). *Learning with Kernels: Support Vector Machines, Regularization, Optimization, and Beyond*. MIT Press.
- NLA Trefethen, LL. y D. Bau (1997). *Numerical Linear Algebra*. Society of Industrial and Applied Mathematics.
- KSM Wand, MP. y MC. Jones (1995). *Kernel Smoothing*. Taylor and Francis Group.
- GAMIR Wood, S. (2006). *Generalized Additive Models: An Introduction with R*. Chapman & Hall /CRC

**Calendario de Actividades:**

Semana	Día	Tema	Referencias
1	Ago 15	Conceptos básicos	ISLAR-2, ESL-2
	Ago 17	Práctica Dirigida	
2	Ago 22	MLG, Regresión Lineal	ISLAR-3, AICDA-4, SPR-4
	Ago 24	Práctica Dirigida	
3	Ago 29	MLG, Logit	ISLAR-4, AICDA-4
	Ago 31	<b>Práctica Calificada 1</b>	
4	Sep 5	Validación cruzada	ISLAR-5
	Sep 7	Práctica Dirigida	
5	Sep 12	Regresión por componentes principales	ISLAR-6, NLA-6
	Sep 14	Práctica Dirigida	
6	Sep 19	Mínimos cuadrados parciales	ISLAR-6, NLA-6
	Sep 21	<b>Práctica Calificada 2</b>	
7	Sep 26	Regresión Ridge y regresión Lasso	ISLAR-6, ESL-3, NLA-4
	Sep 28	Práctica Dirigida	
8 & 9		<b>Semana de exámenes parciales</b>	
10	Oct 17	GAM, Regresión	ISLAR-7, SPR-3, KSM-5
	Oct 19	Práctica Dirigida	
11	Oct 24	GAM, Logit	ISLAR-7, SPR-6
	Oct 26	<b>Práctica Calificada 3</b>	
12	Oct 31	Árboles 1	ISLAR-8, ESL-9
	Nov 2	Práctica Dirigida	
13	Nov 7	Árboles 2	ISLAR-8, ESL-10
	Nov 9	Práctica Dirigida	
14	Nov 14	SVM 1	ISLAR-9, ESL-12, LWK-1
	Nov 16	<b>Práctica Calificada 4</b>	
15	Nov 21	SVM 2	ISLAR-9, ESL-12, LWK-1
	Nov 23	Práctica Dirigida	
16	<b>Semana de exámenes Finales</b>		